

Nome: João Geiger Piza

Explicação da motivação da U-Net:

A motivação principal foi superar a lentidão e o uso redundante de recursos das redes baseadas em janelas deslizantes, além de criar uma arquitetura que pudesse ser bem-sucedida em tarefas de localização de alta precisão a partir de um conjunto muito limitado de amostras de treinamento anotadas.

Explicação sobre segmentação biomédica:

Segmentação biomédica é a tarefa de isolar e classificar estruturas anatômicas, células ou tecidos em exames de imagens ao nível do pixel. Ela exige uma precisão de fronteira muito alta e lida constantemente com a escassez crônica de dados anotados devido ao alto custo dos especialistas.

Resumo do artigo:

O artigo introduz a U-Net, uma rede neural convolucional de arquitetura em "U" capaz de treinar algoritmos de segmentação de imagem de forma eficiente usando pouquíssimas imagens. Ela alcança precisão local e contexto global unindo um caminho de contração com um caminho simétrico de expansão, superando redes convolucionais baseadas em patches e atingindo ótimos resultados em competições de segmentação biomédica de forma muito rápida.

Respostas às questões da leitura guiada:

1. Introdução do artigo:

- 1.1: Esse método é muito lento pois exige que a rede processe de maneira individual cada patch da imagem para prever a classe central, gerando uma quantidade enorme de redundância computacional nas áreas de sobreposição.
- 1.2: Para observar um contexto amplo, a rede precisa processar janelas enormes repletas de camadas de max-pooling, destruindo a precisão fina da localização geométrica exigida pelas bordas.
- 1.3: Janelas enormes empobrecem o detalhe da localização em favor do contexto global, enquanto janelas reduzidas enxergam uma quantidade insuficiente do ambiente da imagem para tomar decisões semânticas corretas.
- 1.4: O grande insight é complementar o caminho contratual que entende "o que é o objeto", construindo um caminho expansivo rico em canais de características simétricos, acoplado com cópias exatas dos mapas de alta resolução para resgatar "onde o objeto está" sem perda.
- 1.5: O modelo emprega estratégias massivas de aumento de dados sobre as poucas amostras originais disponíveis, introduzindo fortes deformações elásticas aleatórias, para ensinar à rede a invariância às variações biológicas típicas dos tecidos sem depender de novos dados reais anotados.
- 1.6: Pois alcançou precisão milimétrica em membranas complexas, lidou com fronteiras difusas com uma função de perda ponderada para células

contíguas e contornou a quase impossibilidade de se obter milhões de exames humanos caríssimos.

2. Arquitetura da U-Net:

- 2.1: Atua extraíndo e condensando eficientemente o contexto global e as representações semânticas profundas da imagem de entrada.
- 2.2: Ele pega esse contexto altamente condensado e progressivamente restaura a resolução espacial da predição final, permitindo o posicionamento de alta acurácia.
- 2.3: Para anexar inalteradamente as características cruas e ricas em geometria ao tensor up-sampled, garantindo que as sucessivas camadas de convolução decidam de modo flexível como compor e utilizar as bordas precisas com os dados já expandidos.
- 2.4: Cada convolução operada no caminho de contração não usa preenchimentos de margens, o que encolhe a imagem fisicamente a cada passe de filtro e força o recorte do mapa antes da concatenação para igualar as larguras na expansão.
- 2.5: Toda informação que escaparia ao redor das fronteiras das amostras durante os recortes em lote é resolvida prevendo a continuidade virtual ao gerar reflexos dos pixels de entrada sobre o eixo marginal.
- 2.6: A camada final de convolução dimensional 1x1 existe primariamente para reduzir o vetor profundo de características e transformá-lo perfeitamente no número final de mapas de probabilidade exigidos pelas classes.
- 2.7: As skip connections impedem o vazamento de morfologias preciosas causadas pelos passos agressivos de amostragem negativa, mantendo intactas a topologia real dos exames de imagem diretamente na saída final do pixel.

3. Resultados do artigo:

- 3.1: O artigo demonstra ótimas performances na predição de bordas em micrografias eletrônicas de cordões nervosos de larvas e também no rastreamento e segmentação celular de imagens PhC-U373 e DIC-HeLa da competição celular ISBI 2015.
- 3.2: O modelo apresenta mais ganhos em velocidade, segmentando blocos robustos de 512x512 pixels em menos de 1 segundo, e também na entrega de precisão simultânea entre o contexto da região e o contorno fino local.
- 3.3: O erro de deformação, o erro de Rand e o erro por pixel demonstraram o ganho de desempenho na Microscopia Eletrônica, enquanto as predições celulares com contrastes normais utilizaram a pontuação de IoU.
- 3.4: O PhC-U373 avalia células em substrato de poliacrilamida registradas por contraste de fase com 35 imagens de treino parciais, enquanto o DIC-HeLa foca em células em vidro plano registradas por contraste de interferência

diferencial (DIC) utilizando 20 imagens de treino.

- 3.5: O modelo é computacionalmente rápido, atinge alta performance com muitas poucas amostras anotadas devido à estratégia de aumento de dados e possibilita a segmentação de imagens de tamanhos arbitrários pela técnica de overlap-tile.
- 3.6: Porque permite alcançar resultados ótimos de forma direta na imagem, sem depender de métodos e etapas complexas de pós-processamento que são altamente específicas e ajustadas apenas para um conjunto de dados particular.

4. Após a leitura:

- 4.1: A principal contribuição é a combinação da arquitetura em "U" estruturada com as skip connections baseadas em concatenação. Isso resolveu o problema crônico das redes convolucionais para segmentação, demonstrando mecanicamente como resgatar a precisão espacial descartada no processo de pooling sem perder a semântica processada nas camadas profundas.
- 4.2: Refere-se à capacidade da rede neural de receber a imagem original bruta como entrada e produzir o mapa de segmentação final predito como saída direta, processando todo o mapeamento espacial em um único fluxo de otimização.
- 4.3: Ele acabou com a necessidade de desenhar manualmente os extratores de características e de usar múltiplos algoritmos independentes em cascata, automatizando a identificação de padrões morfológicos complexos que antes dependiam do ajuste exaustivo por especialistas.
- 4.4: Ela utiliza conexões que realizam cópias exatas dos mapas de características de alta resolução do caminho de contração, que são recortados e concatenados com a saída de resolução correspondente no caminho de expansão.
- 4.5: A incorporação de módulos baseados em convoluções dilatadas/espaçadas na camada mais profunda, o que permitiria à rede capturar o contexto do tecido anatômico em diferentes campos receptivos simultaneamente.
- 4.6: A substituição da Cross-Entropy Loss por funções de perda otimizadas para distribuições assimétricas de área, como a Dice Loss ou a Focal Loss.
- 4.7: O experimento seria estruturado modularizando a rede em classes específicas para cada parte desta, que seriam instanciadas dentro de uma classe principal UNet. O pipeline de treinamento seria configurado utilizando a função de perda Binary Cross Entropy com Logit (BCEWithLogitsLoss) e o otimizador Adam com taxa de aprendizado de $1e-4$, processando batches de tamanho 4 ao longo de 25 épocas. Para a etapa de aumento de dados, utilizaria a biblioteca albumentations para aplicar transformações geométricas dinâmicas no carregamento dos tensores, como espelhamento horizontal, espelhamento vertical e rotações com mudança de escala (shift scale rotate),

todas configuradas com 20% de probabilidade de ativação.

- 4.8: Devido ao uso exclusivo de pequenas janelas convolucionais, a arquitetura clássica apresenta limitações na captura de interações de longa distância e contexto global simultâneo na imagem, algo que arquiteturas modernas híbridas com Transformers resolvem de forma muito mais eficaz.

Explicação sobre o caminho de contração:

O lado esquerdo da rede serve para capturar o contexto abrangente da imagem através da aplicação sucessiva de blocos compostos por duas convoluções 3x3 não-preenchidas e operações de redução de resolução por max-pooling 2x2, dobrando o número de canais de características em cada etapa.

Explicação sobre o caminho de expansão:

O lado direito simétrico da rede é desenhado para permitir a localização precisa ao recuperar a resolução das características da imagem, utilizando operações sucessivas de upsampling e convoluções 2x2 para reduzir os canais pela metade, que depois recebem os recortes originais do caminho de contração seguidos de convoluções 3x3.

Explicação sobre as skip connections:

Para reconstruir a localização exata, os mapas de características de alta resolução provenientes do caminho de contração são copiados e diretamente concatenados aos mapas gerados pelo correspondente passo de upsampling no caminho de expansão, fornecendo a referência espacial exata perdida no pooling.

Explicação sobre a estratégia overlap-tile:

Trata-se de uma estratégia que garante a segmentação sem emendas de imagens gigantescas, alimentando a rede em blocos, onde os pixels de saída dependem exclusivamente das regiões com contexto completo na entrada. Bordas ausentes são simuladas espelhando a própria imagem original de entrada.